

Documentation technique

Documentation officielle

Table des matières

Introduction et contexte.....	2
Architecture	3
Présentation des différents scripts	4

Introduction et contexte

Ce projet s'articule en deux parties.

- 1) Prédire le nombre de cyclistes circulant sur la voie réservée aux vélo place de Bretagne à Rennes
- 2) Utiliser ces prédictions pour résoudre des problèmes métiers (parmi les projets identifiés : Installer des stands pour sensibiliser les cyclistes à l'entretien de leur vélo et Informer les professionnels livreurs du centre-ville des pics de circulation cycliste afin d'éviter des accidents et congestions)

Dans cette documentation nous allons nous concentrer sur la prédiction du nombre de cycliste à une heure précise. Cela constitue la base sur laquelle reposeront les projets métiers.

Ce projet a pour objectif d'analyser des données de comptage de vélos et de mettre en place un pipeline simple allant de la préparation des données jusqu'à l'entraînement et à l'évaluation de modèles de Machine Learning.

Les données correspondent à des comptages horaires de passages cyclistes provenant d'un compteur situé à Rennes (Place de Bretagne).

Le projet est organisé en deux grandes étapes :

- Préparation et nettoyage des données ;
- Entraînement, évaluation et documentation des modèles.

L'objectif de la modélisation est de prédire le nombre de passages cyclistes pour une heure donnée à partir des observations passées et de caractéristiques temporelles.

Architecture

Le projet suit une organisation simple inspirée d'une architecture **Bronze / Silver**.

- **Bronze** : données brutes, conservées sans modification.
- **Silver** : données nettoyées et préparées pour l'analyse et la modélisation.
- **Models** : modèles entraînés, métriques, prédictions, graphiques et Model Cards.

Structure générale :

projet/

|

|— data/

|

| |— bronze/

|

| | |— données brutes

|

|

| |— silver/

|

| |— données nettoyées

|

|— scripts/

|

| |— Bronze2silver.py

|

| |— ModelCreation&ModelCard.py

|

|— models/

|

| |— xgboost_168h/

|

| | |— modèle

|

| | |— métriques

|

| | |— prédictions

|

| | |— model_card.md

|

| |— figures/

Présentation des différents scripts

Préparation Bronze → Silver

Script : Bronze2silver.py

Ce script transforme les données brutes en données exploitables.

Il réalise notamment :

- la conversion et la normalisation des dates ;
- la suppression des colonnes inutiles ou redondantes ;
- la vérification des valeurs de comptage ;
- la détection des doublons ;
- le tri chronologique ;
- le contrôle des valeurs manquantes ;
- la création des variables temporelles nécessaires à la modélisation ;
- l'export du dataset Silver.

Une documentation du nettoyage et des contrôles effectués est également générée.

Documentation du nettoyage : [<LIEN_DOCUMENTATION_NETTOYAGE>](#)

Dataset Silver : [<LIEN_DATASET_SILVER>](#)

Modèle XGBoost avec lag 168h

Script : [<LIEN_SCRIPT_XGBOOST_168H>](#)

Ce second modèle utilise le nombre de passages observé **168 heures auparavant**, soit une semaine.

Il permet d'étudier la saisonnalité hebdomadaire du trafic cycliste.

Le fonctionnement est identique au modèle précédent, avec une comparaison à une baseline J-7.

Model Card : [<LIEN_MODEL_CARD_168H>](#)

Métriques : [<LIEN_METRICS_168H>](#)

Prédictions : [<LIEN_PREDICTIONS_168H>](#)

Données

Les données contiennent des observations horaires du nombre de passages cyclistes.

Les données brutes comportent notamment la date, le nombre de passages ainsi que plusieurs métadonnées liées au compteur.

Après nettoyage, le dataset Silver conserve uniquement les informations utiles à l'analyse et à la modélisation.

Les principales variables utilisées sont :

Variable	Description
date	Date et heure de l'observation
counts	Nombre de passages cyclistes
matin	Indicateur de la période du matin
midi	Indicateur de la période du midi
soir	Indicateur de la période du soir
nuit	Indicateur de la période de nuit
day_of_week	Jour de la semaine
lag_24h	Nombre de passages 24 heures auparavant
lag_168h	Nombre de passages 168 heures auparavant

Les valeurs manquantes présentes dans les données sources ne sont pas remplacées artificiellement par zéro. Une absence de mesure ne signifie pas une absence de passage.

Dataset brut : [<LIEN_DATASET_BRONZE>](#)

Dataset nettoyé : [<LIEN_DATASET_SILVER>](#)

Modèle

Le problème est traité comme un problème de **régression** : la variable à prédire est le nombre de passages cyclistes counts.

Le modèle utilisé est **XGBoost Regressor**.

Deux expériences sont réalisées :

- XGBoost avec un lag de **24 heures** ;
- XGBoost avec un lag de **168 heures**.

Les données sont séparées chronologiquement afin de respecter leur nature temporelle. Les observations les plus anciennes servent à l'entraînement et les plus récentes au test.

Les performances sont évaluées avec :

- **MAE** : erreur absolue moyenne ;
- **RMSE** : erreur quadratique moyenne ;
- **R²** : proportion de la variance expliquée.

Chaque modèle est également comparé à une baseline simple :

- lag 24h → baseline J-1 ;
- lag 168h → baseline J-7.

Les modèles sont analysés à l'aide de graphiques de convergence, de comparaison entre prédictions et valeurs réelles, de résidus, d'importance des variables et de performances selon la période de la journée.

Les résultats détaillés et les limites de chaque modèle sont disponibles dans leurs Model Cards :

- XGBoost 168h : [<LIEN_MODEL_CARD_168H>](#)

Les modèles entraînés sont disponibles ici :

- Modèle 168h : [<LIEN_MODELE_168H>](#)